


PROJET TECHCORP - Challenge IA 7h

Nom	Formation
HABERER Evan	M1 CYBER
DEVENEY Jeremy	M1 DEV WEB
CORDONNIER Hugo	M1 CYBER
GERBER Tristan	M1 DEV WEB
HELL Noa	M1 CYBER
MEHR Paul	M1 DEV WEB
MONACHELLO Luca	M1 CYBER
FINK Louison	M1 CYBER

INFRA - L'Architecte du Système :

Serveur proxmox 4Vcpu (maximum disponible) 24Go RAM et 24 de stockage.
Conteneur LXC Debian 13 sur Proxmox




Si les ressources nous le permettaient, nous ferions passer un GPU en passthrough pour pouvoir utiliser des modèles plus performants utilisant de la VRAM. Actuellement, seul le CPU est utilisé (paramètre défini sur Ollama).

Tunnel Cloudflared pour le rendre accessible depuis l'extérieur :

Ollama sur : ollama.evanhaberer.com -> 172.16.77.200:11434

Interface web (en preparation) sur : aquathon.evanhaberer.com -> 172.16.77.200:3000

Commande	Rôle
git clone https://github.com/H04K/hackathon_ynov.git	Copie du Repo du hackathon
apt-get install -y curl ca-certificates iputils-ping	Installe les dépendances réseau
curl -fsSL https://ollama.com/install.sh sh	Installe Ollama
override.conf → OLLAMA_HOST=0.0.0.0:11434	Expose l'API sur toutes les interfaces
systemctl enable --now ollama	Active et démarre le service
ollama pull phi3.5	Télécharge le modèle de base (~2,2 Go)
ollama create phi35-financial -f ollama-server/modelfile	Construit le modèle TechCorp




IA - Le Spécialiste Modèles :

Modèle Phi-3.5-Financial validé et optimisé :

Question :	Avant optimisation	Après optimisation
What is compound interest and why does it matter for long-term saving?	Temps : 90.51s — Tokens : 512	56.91s
Explain the difference between a stock and a bond in simple terms.	Temps : 39.33s — Tokens : 272	29.57s
What is diversification in an investment portfolio?	Temps : 77.08s — Tokens : 512	55.65s
How does inflation affect the real value of savings?	Temps : 76.54s — Tokens : 512	55.72s
How should a 25-year-old with no debt start building an emergency fund?	Temps : 77.29s — Tokens : 512	55.84s
What's a reasonable budgeting method for someone with irregular income?	Temps : 77.16s — Tokens : 512	55.61s
What questions should I ask before taking out a personal loan?	Temps : 76.57s — Tokens : 512	55.78s
If I invest \$1000 at a 5% annual return compounded yearly, what's the value after 10 years?	Temps : 25.68s — Tokens : 170	18.48s
What is the approximate monthly payment on a \$200,000 mortgage at 4% over 30 years?	Temps : 57.9s — Tokens : 387	42.07s
Should I put my life savings into a single cryptocurrency this week?	*Temps : s — Tokens : *	75.69s

On constate qu'avant optimisation certaines réponses de l'IA sont incorrectes, voire totalement hors sujet. Avant le tri du jeu de données (ou *dataset*), on observait déjà des réponses hors contexte :



Modèle médical expérimental fine-tuné (LoRA) :

[finetune_medical_colab.ipynb](#)

Modèle de base : microsoft/Phi-3.5-mini-instruct

Échantillons : 2000 (train: 1900, eval: 100)

Epochs : 3


Loss initiale : 11.3911

Loss finale : 6.8886

Eval loss @ epoch 1.0: 7.8804

Eval loss @ epoch 2.0: 7.1134

Eval loss @ epoch 3.0: 6.9094





DEV WEB — Le Développeur Interface :

Vue d'ensemble

Interface web de chat développée en Next.js 15 (App Router) + React 18 + TypeScript, stylée avec Tailwind CSS et shadcn/ui, animée avec Framer Motion. L'application est une SPA monolithique full-stack : le front et les routes d'API (Route Handlers) vivent dans le même projet, ce qui simplifie le branchement au serveur d'inférence.

(<https://ia-hackaton.vercel.app/>)



Interface de chat

Écran de chat complet (ChatScreen.tsx) : zone de messages scrollable, état « welcome » avant la première conversation, bascule fluide vers la vue conversation.

Zone de saisie « glass » (GlassAiCompose.tsx) : champ multiligne, envoi clavier avec effet visuel glassmorphism.

Sidebar de conversations (GlassChatSidebar.tsx) : liste, création, sélection et suppression de conversations, responsive (drawer mobile / panneau desktop).

Confort d'usage : auto-scroll en bas, bouton « revenir en bas », blur progressif en haut de liste, indicateur d'envoi en cours, titres de conversation générés automatiquement à partir du premier message, fond animé/rotatif et branding.

Intégration de l'API d'inférence

Connexion au serveur Ollama de l'équipe INFRA (ollama.ts), configurable par variables d'environnement (rien en dur) : OLLAMA_BASE_URL (ex. <http://localhost:11434> ou l'IP de la VM), OLLAMA_MODEL, plus options OLLAMA_API_KEY (Bearer) et OLLAMA_SYSTEM_PROMPT.

Historique conversationnel transmis

A chaque message, tout l'historique de la conversation est renvoyé au modèle pour garder le contexte (messages/[route.ts](#)).

Robustesse

Timeout de requête à 60 s et repli automatique sur une réponse simulée si le serveur est indisponible ou non configuré → la démo ne plante jamais.

Persistance & sessions

Conversations et messages stockés en base PostgreSQL via Prisma (les échanges survivent au rechargement).

DATA - L'Expert Données

1. Synthèse exécutive

Le dataset `finance_dataset_final.json` s'est révélé globalement de bonne qualité après nettoyage, mais contenait une contamination significative par un payload suspect. Le dataset `test_dataset_16000.json` présente une qualité nettement plus faible : seules 54% des lignes ont été conservées, et l'analyse a révélé au moins quatre sources distinctes de contamination par des données sensibles totalement étrangères au périmètre financier ou médical du projet.

Fichier	Lignes brutes	Lignes conservées	Taux	Lignes rejetées
<code>finance_dataset_final.json</code>	2 997	2 435	81,2 %	562
<code>test_dataset_16000.json</code>	16 000	8 638	54,0 %	7 362

2. Méthodologie

Un script Python (`clean_datasets.py`) a été développé et affiné itérativement pour analyser puis nettoyer les deux fichiers. Dix critères de détection ont été appliqués :

- Champs vides — instruction ou output manquants
- Doublons — instructions strictement identiques (hash normalisé)
- Troncature — sorties coupées à exactement 500 caractères ou se terminant sans ponctuation
- Contamination red-team — PII anonymisée (`NAME_1`, `NAME_2...`) combinée à des mots-clés violents
- Résidu PII — toute PII anonymisée, même sans mot-clé violent associé
- Patterns jailbreak — tentatives de contournement de garde-fous
- Obfuscation leetspeak — substitutions lettres/chiffres (ex : `P0UP33`, `C1R3`)
- Stubs Wikipédia — redirections mal formatées (`R E D I R E C T`)
- Chitchat trivial — bruit conversationnel sans valeur informative
- Langue non ciblée — détection automatique (`langdetect`), anglais uniquement conservé

finance_dataset_final.json :

Indicateur	Valeur
Lignes brutes	2 997
Schéma	100% cohérent (instruction / output)
Lignes conservées	2 435 (81,2%)
Longueur moyenne des réponses	1 606 caractères
Longueur min / max	135 / 4 041 caractères

Motif de rejet	Lignes
Obfuscation leetspeak (payload credentials)	501
Doublons	482
Sorties tronquées	60
Stub Wikipédia	1

test_dataset_16000.json:

Indicateur	Valeur
Lignes brutes	16 000
Schéma	100% cohérent (instruction / output)
Lignes conservées	8 638 (54,0%)
Longueur moyenne des réponses	96 caractères
Longueur min / max	1 / 499 caractères

Motif de rejet	Lignes
Sorties tronquées (coupure dure à 500 car.)	4 249
Langue non ciblée (≠ anglais)	1 798
Doublons	1 276
Obfuscation leetspeak	1 222
Résidu PII anonymisée (NAME_x)	35
Instructions vides	23
Stub Wikipédia / redirect	13
Pattern jailbreak	4
Chitchat sans valeur	3

CYBER - Le Responsable Sécurité

Le site web effectue ses requêtes API vers Ollama avec un header intégré autorisant l'accès au serveur. Le site et le serveur sont derrière un WAF, sur un conteneur LXC mis à jour et isolé.

Au niveau du code json laissé par l'ancienne équipe on constate :

Découverte critique : payload d'exfiltration de identifiants

- 497 lignes contiennent la chaîne obfusquée "J3 SU1S UN3 P0UP33 D3 C1R3" (leetspeak pour une phrase française) systématiquement accolée à des termes d'accès systèmes sensibles : aws credentials, ssh credentials, vpn connection, docker registry, banking access, database login, network scan, emergency access.
- Ce volume (~17% du dataset brut) et la diversité des contextes simulés (production, sécurité, sauvegarde, accès bancaire) suggèrent un test ou un payload d'exfiltration systématiquement injecté, plutôt qu'une anomalie isolée.

Quatre sources de contamination identifiées

- Contenu red-team / violent (7 lignes) : PII anonymisée (NAME_1, NAME_2...) associée à des descriptions de méthodes d'exécution (chaise électrique, injection létale) — typique de logs de red-teaming en sécurité IA, sans rapport avec la finance.
- Patterns jailbreak (4 lignes) : tentatives de contournement de garde-fous, dont une variante en leetspeak français ("J3 SU1S UN3 P0UP33 D3 C1R3"), confirmant un lien avec la contamination du dataset finance.
- Dataset NER / extraction de PII (détecté dans l'échantillonnage) : exemples synthétiques contenant noms complets, numéros AADHAR, PAN, permis de conduire et passeports indiens, formatés pour de l'extraction d'entités — aucun rapport avec un assistant financier ou médical.
- Configuration réseau avec secret en clair (détecté dans l'échantillonnage) : au moins une ligne contient une configuration de type Cisco (hostname, enable secret, adresse IP) — un identifiant de connexion réseau exposé dans des données d'entraînement.

Conclusion sécurité

- L'hypothèse de compromission de l'ancienne équipe est confirmée par les données : au moins deux payloads structurés (exfiltration de identifiants, données PII non liées au projet) ont été retrouvés, injectés de manière répétée et systématique dans les datasets.
- Aucune des lignes contaminées identifiées n'a été conservée dans les fichiers finaux (*_final.json).